

Análise de intervenção e previsão de atividade econômica

Lucas Emanuel Resck Domingues*

Lucas Machado Moschen†

TODO

(DONE) 1. Fazer o processo de identificação manualmente para obter a primeira opção de modelo (mostrar que aprendemos isso).

(DONE) 2. Usar `auto.arima` para um segundo modelo. Se eles forem diferentes (o drift faz variar), comparamos os modelos usando `checkresiduals`. Escolher o “melhor modelo”

(DONE) 3. Fazer previsões do modelo e comparar com pósintervenção. Vamos comparar com a realidade e verificar que de fato houve efeito.

4. Fitar o modelo em todos os dados: propor um modelo para a crise (talvez dois e repetir a escolha do melhor?)

5. Fazemos as previsões e avaliamos o modelo no teste (podemos comparar com um `naive`).


Obs.: Esses 5 passos combrem a Metodologia, mas podemos adicionar algumas cerejas para deixar mais rico, dependendo do tempo.

Dados

A série temporal é o total de vendas mensais nos negócios em milhões de dólares, obtido em Fred, Federal Reserve Bank of St. Louis. A janela de observações será entre Janeiro de 2002 a Dezembro de 2014, em que os últimos dois anos são utilizados para a validação do modelo de previsão.

*Escola de Matemática Aplicada

†Escola de Matemática Aplicada



Vamos separar os últimos dois anos para validação do modelo e portanto, não usaremos no treinamento do modelo.

Vamos considerar que houve uma intervenção (a crise sub-prime) em julho de 2008.

1. Modelagem pré-intervenção

Antes vamos fazer a modelagem do processo antes da crise. Assim, poderemos verificar que de fato houve efeito pós intervenção.


1. Modelagem manual Box-Jenkins

Para isso, vamos seguir a metodologia Box-Jenkins. Primeiro, faremos uma transformação Box-Cox na série, se utilizando do λ que minimiza o coeficiente de variação para subséries da série.

```
## [1] "Obtemos lambda = -0.222584674825719"
```

Agora, vamos remover a tendência diferenciando a série.


Diferença mensal de vendas nos negócios



Com a série diferenciada, vamos checar a sazonalidade anual, como sugerido:

```
##  
## Kruskal-Wallis rank sum test  
##  
## data: pre_intervention.d and cycle(pre_intervention.d)  
## Kruskal-Wallis chi-squared = 66.041, df = 11, p-value = 6.862e-10
```

Como o p-valor é pequeno, temos evidência para rejeitar a hipótese nula do teste, o que nos dá suporte para diferenciar a série sazonalmente. Após a diferenciação, podemos ver que a ACF e a PACF não apresentam picos nos lags múltiplos de 12.



Assim, com o teste ADF rejeitando a não estacionariedade, podemos partir para identificar o modelo.

```
## Warning in adf.test(pre_intervention.bc): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: pre_intervention.bc
## Dickey-Fuller = -4.191, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary
```

Vemos uma ACF decaindo exponencialmente e uma PACF morrendo após o lag 2. Assim imaginamos um modelo AR com grau não maior do que 3. Vamos testar essa ideia com os critérios de informação. Além disso, não percebemos nenhum LAG significativo sazonal, o que pode indicar um MA(1) ou não ter componentes autorregressivos ou de média móvel sazonais. Vamos testar esses modelos também com os critérios de informação. O modelo de teste ARIMA(3,1,3) teve problema de estacionariedade e foi retirado da análise.

Podemos observar que sem sazonalidade, o melhor modelo segundo os três critérios de informação foi ARMA(2,0) como já tínhamos imaginado. Considerando a sazonalidade, o melhor modelo fica, ao todo

ARIMA(2,1,0)(0,1,1)[12]

##	p	q	AIC	BIC	AICc	AIC (S)	BIC (S)	AICc (S)
## 1	0	0	-679.1115	-676.9371	-679.0480	-677.4750	-673.1262	-677.2815
## 2	0	1	-706.1459	-701.7971	-705.9524	-705.4041	-698.8809	-705.0106
## 3	0	2	-706.7266	-700.2034	-706.3331	-708.4334	-699.7359	-707.7668
## 4	1	0	-697.5741	-693.2253	-697.3805	-695.6333	-689.1101	-695.2398
## 5	1	1	-705.8174	-699.2942	-705.4240	-706.0822	-697.3846	-705.4155
## 6	1	2	-704.7680	-696.0705	-704.1014	-706.4932	-695.6212	-705.4762
## 7	2	0	-710.9575	-704.4343	-710.5640	-717.9966	-709.2990	-717.3299
## 8	2	1	-709.3628	-700.6653	-708.6962	-716.5123	-705.6404	-715.4953


```
## 9  2 2 -707.3870 -696.5151 -706.3700 -714.5490 -701.5027 -713.1007
## 10 3 0 -709.2816 -700.5841 -708.6150 -716.4277 -705.5558 -715.4108
## 11 3 1 -707.3690 -696.4970 -706.3520 -714.5186 -701.4722 -713.0703
## 12 3 2 -707.3121 -694.2658 -705.8638 -712.8482 -697.6275 -710.8833
```

Agora que já identificamos o modelo, podemos estimá-lo.

```
## Series: pre_intervention
## ARIMA(2,1,0)(0,1,1)[12]
## Box Cox transformation: lambda= -0.2225847
##
## Coefficients:
##          ar1      ar2      sma1
##      -0.8633  -0.6094  -0.6911
## s.e.   0.0961   0.0994   0.2242
##
## sigma^2 estimated as 4.585e-06:  log likelihood=363
## AIC=-718   AICc=-717.33   BIC=-709.3
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -1902.353 38156.23 18285.63 -0.2765078 1.947999 0.2891937
##              ACF1
## Training set 0.1325941
```

Agora com o modelo treinado, podemos fazer uma checagem sobre os resíduos:

```
checkresiduals(model11)
```



```
##
## Ljung-Box test
##
## data: Residuals from ARIMA(2,1,0)(0,1,1)[12]
## Q* = 9.3584, df = 13, p-value = 0.7454
##
## Model df: 3. Total lags used: 16
```

```
jarque.bera.test(model1$residuals)
```

```
##
## Jarque Bera Test
##
## data: model1$residuals
## X-squared = 6926.5, df = 2, p-value < 2.2e-16
```


Observamos que existe um resíduo bem deslocado que no ano de 2003 quando houve uma queda que o modelo não conseguiu capturar. Além disso, não aparenta uma normalidade, inclusive tendo-a rejeitada pelo teste Jarque-Bera. Por fim, as correlações estão bem interessantes, dentro das margens e, o teste de Ljung-Box não rejeitou a hipótese de decorrelação. Isso é um bom indício, porém a não normalidade dos dados indica algum problema.

2. Modelo auto.arima

Vamos averiguar uma segunda opção de modelo que pode ser encontrada automaticamente, utilizando a função `auto.arima`. Assim, vemos que o modelo estimado tem drift e é do tipo

ARIMA(3,0,0)(2,1,0)[12].

```
## Series: pre_intervention
## ARIMA(3,0,0)(2,1,0)[12] with drift
## Box Cox transformation: lambda= -0.2225847
##
## Coefficients:
##          ar1      ar2      ar3      sar1      sar2  drift
##          0.1015  0.1235  0.5118 -0.3434 -0.4384  3e-04
## s.e.      0.1104  0.1156  0.1119  0.1419  0.1616  2e-04
##
## sigma^2 estimated as 4.413e-06: log likelihood=371.16
## AIC=-728.32  AICc=-726.39  BIC=-712.99
##
## Training set error measures:
##          ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 10721.76 32202.53 23457.97 1.270498 2.547099 0.370996 0.6357849
```



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(3,0,0)(2,1,0)[12] with drift
## Q* = 159.32, df = 10, p-value < 2.2e-16
##
## Model df: 6.    Total lags used: 16
##
##  Jarque Bera Test
##
## data:  model2$residuals
## X-squared = 17.463, df = 2, p-value = 0.0001614
```

Pela ACF, os erros certamente tem correlação, a princípio uma correlação autorregressiva, e também existe uma assimetria no histograma. Esses fatos são confirmados com os testes, dado que rejeitamos ambas as hipóteses nulas, isto é, temos evidência para assegurar que não há normalidade e existe correlação nos resíduos. As medidas dos erros de treinamento também não são melhores do que o modelo 1.

3. Modelo auto.arima com variação


Fazendo algumas experimentações com o `auto.arima` podemos chegar num fato interessante colocando $\lambda = 0$.

```
## Series: pre_intervention
## ARIMA(3,0,0)(2,1,0)[12] with drift
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ar1      ar2      ar3      sar1      sar2      drift
```

```
##      0.1055  0.1302  0.5103  -0.3279  -0.4297  0.0055
## s.e.  0.1105  0.1088  0.1116   0.1425   0.1418  0.0004
##
## sigma^2 estimated as 0.0003932:  log likelihood=168.3
## AIC=-322.59  AICc=-320.66  BIC=-307.27
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 1907.311 17686.81 14286.31 0.1881717 1.442845 0.225943 0.106949
```

Conseguimos um modelo com todas as medidas de erro menores e, além disso

Residuals from ARIMA(3,0,0)(2,1,0)[12] with drift



```
##
## Ljung-Box test
##
## data:  Residuals from ARIMA(3,0,0)(2,1,0)[12] with drift
## Q* = 21.302, df = 10, p-value = 0.01908
##
## Model df: 6.   Total lags used: 16
##
## Jarque Bera Test
##
## data:  model3$residuals
## X-squared = 1.7383, df = 2, p-value = 0.4193
```

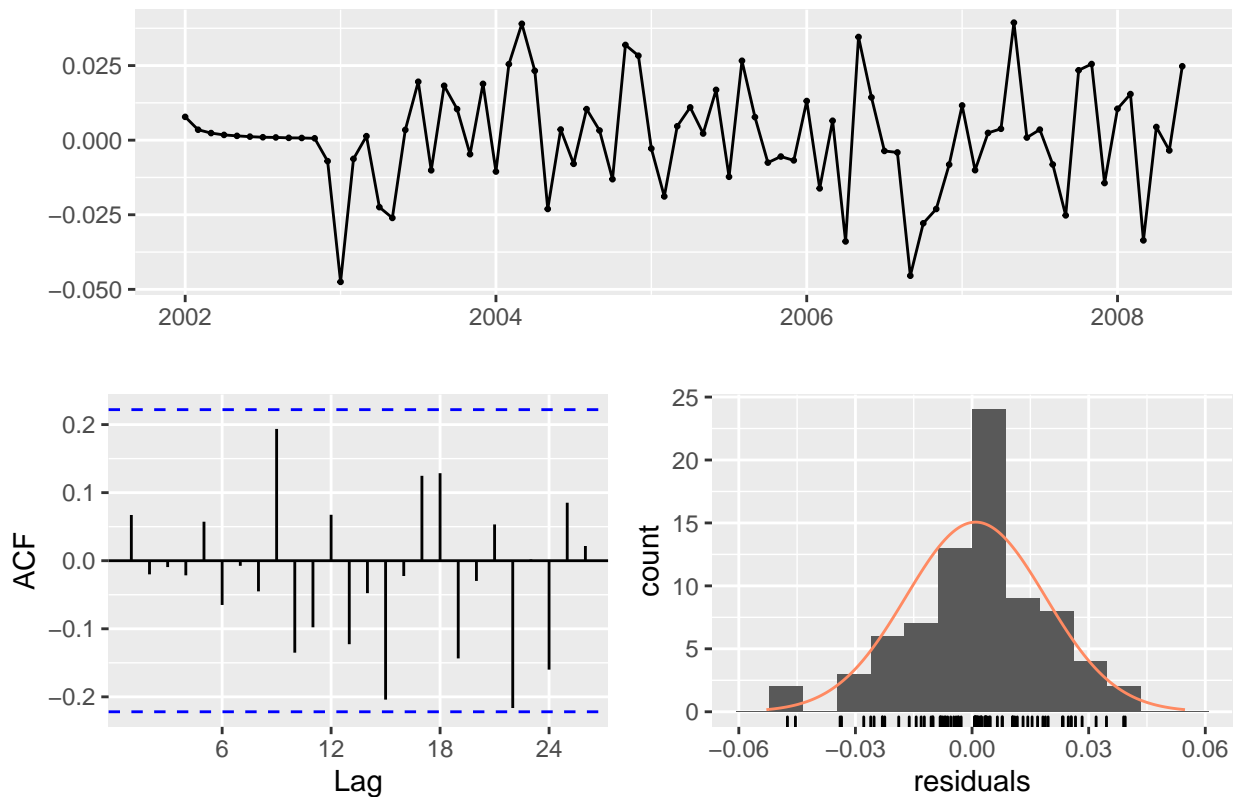
Note que os resíduos aparentam muito mais uma normalidade do que antes, o que também é indicado pelo teste Jarque Bera. Porém o teste Ljung-Box rejeita a hipótese nula, o que mostra que ainda existe uma correlação nos resíduos.

4. Modelo manual com variação

Utilizando o modelo inicial com a variação de λ , temos:

```
## Series: pre_intervention
## ARIMA(2,1,0)(0,1,1)[12]
## Box Cox transformation: lambda= 0
##
## Coefficients:
##          ar1      ar2      sma1
##      -0.8617  -0.6038  -0.6408
## s.e.   0.0971   0.1003   0.2063
##
## sigma^2 estimated as 0.0004012:  log likelihood=163.05
## AIC=-318.1   AICc=-317.44   BIC=-309.41
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 1017.575 18230.79 13580.72 0.07746272 1.3489 0.2147838 0.05014901
```

Residuals from ARIMA(2,1,0)(0,1,1)[12]



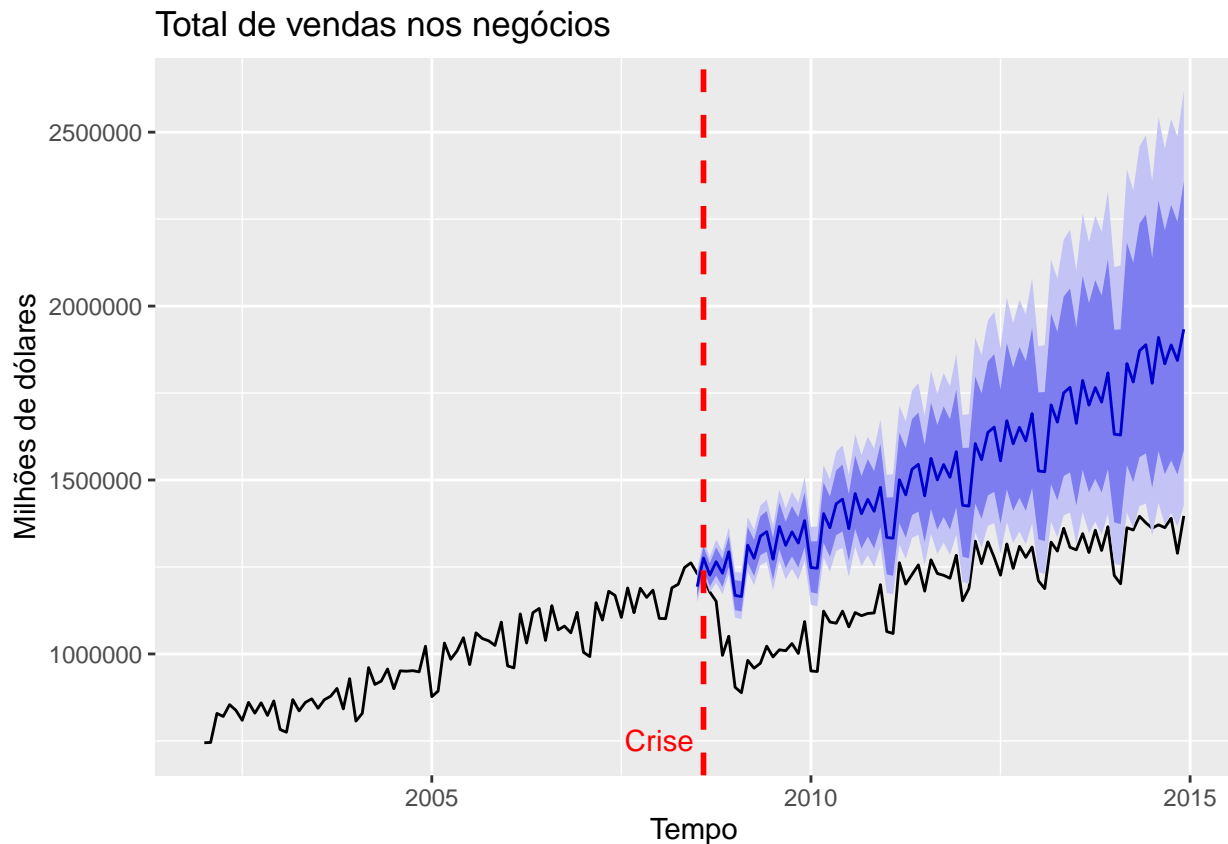
```
##
## Ljung-Box test
##
## data: Residuals from ARIMA(2,1,0)(0,1,1)[12]
## Q* = 13.505, df = 13, p-value = 0.4096
##
## Model df: 3. Total lags used: 16
##
```

```
## Jarque Bera Test
##
## data: model4$residuals
## X-squared = 1.0435, df = 2, p-value = 0.5935
```

Temos resíduos com uma cara de normalidade e a ACF dentro das faixas de confiança, indicando um processo decorrelacionado. Tanto Jarque Bera quanto Ljung Box não rejeitam suas hipóteses nulas, o que nos dá evidência para confirmar que os resíduos formam algo similar a um ruído branco. Os erros de treino também aparentam estar bem em relação ao modelo inicial.

Desta forma, fica claro que o modelo 4 é o mais indicado para representar a série antes da intervenção.

Previsões do modelo e comparação pós intervenção



Observamos graficamente que as previsões de nosso modelo ficam em um patamar mais alto do que os dados reais e por isso tomamos como hipótese de que a crise foi significativa. Consideramos os procedimentos sugeridos por Box e Tiao (1976) com a checagem do erro de previsão.

Seja a estatística

$$Q = \sum_{j=1}^m a_j^2 / \hat{\sigma}_a^2$$

onde $a_j = Z_j - \hat{Z}_{j-1}(1)$, $j = 1, \dots, m$. Sabemos que Q segue uma distribuição $\chi^2(m)$ quando m é grande.

```
## [1] "Q = 262043736328174"
```

Temos que o valor de Q é suficientemente alto para que vejamos que de fato há efeito da crise sub-prime.

Podemos, então, partir para a modelagem da intervenção.

Modelagem com intervenção


Consideraremos o modelo de intervenção dado por uma série que muda de nível abruptamente, dado a quebra do sistema bancário que tem efeito rápido e com um decaimento do efeito exponencial, dado que a economia se autoregula. Suporemos que não hajam outras intervenções, como governamental, e elas devem ser incorporadas no modelo. Seja ele:

$$u_t = \begin{cases} 0, & t < \text{julho 2018} \\ \delta^k \omega_0, & t = \text{julho 2008} + k, k = 0, 1, 2, \dots \end{cases}$$

Estimaremos em toda série esses parâmetros também (δ e ω_0).

```
##
## Call:
## arimax(x = tbs_train.bc, order = c(2, 1, 0), seasonal = c(0, 1, 1), method = "ML",
##       xtransf = data.frame(Crise = 1 * (seq(tbs_train) == (length(pre_intervention) +
##       1))), transfer = list(c(1, 1)))
##
## Coefficients:
##          ar1          ar2          sma1  Crise-AR1  Crise-MA0  Crise-MA1
##      -0.3819  -0.2178  -1.0000    0.5869    0.0779    0.0075
## s.e.   0.0919   0.0967   0.1005    0.1552    0.0246    0.0275
##
## sigma^2 estimated as 0.0006087:  log likelihood = 255.02,  aic = -498.04
##
## Training set error measures:
##              ME          RMSE          MAE          MPE          MAPE          MASE
## Training set -0.00120422  0.02380378  0.01769409 -0.00882782  0.1275692  0.3507759
##              ACF1
## Training set 0.08265493
```

Vamos ver como se comportam os resíduos do modelo.



A ACF dos resíduos e a PACF estão com picos, o que indica que ainda existe uma correlação não capturada. Vamos ver como o modelo fitado se compara com os dados reais na escala log, dada a transformação BoxCox com $\lambda = 0$ que fizemos.

Comparação dos dados reais com o modelo

