

Identificação de Modelos ARIMA

Lucas Resck e Lucas Moschen

October 13, 2020

1. (Questão 30 - 5) Considere o modelo abaixo.

$$Z_t = \sum_{j=0}^m \beta_j t^j + \frac{\theta(B)}{\phi(B)\Delta^d} a_t$$

Prove que, se $m > d$:

- a. Tomando-se d diferenças, obtemos um modelo não estacionário, com uma tendência polinomial de grau $m - d = h$.

Temos que $\Delta^d Z_t = (1 - B)^d Z_t = \sum_{k=0}^d \binom{d}{k} (-1)^k B^k Z_t$, usando o binômio de Newton. Em particular:

$$\begin{aligned} \Delta^d t^j &= \sum_{k=0}^d \binom{d}{k} (-1)^k B^k t^j \\ &= \sum_{k=0}^d \binom{d}{k} (-1)^k (t - k)^j \\ &= \sum_{k=0}^d \binom{d}{k} (-1)^k \sum_{i=0}^j \binom{j}{i} t^i k^{j-i} (-1)^{j-i} \\ &= \sum_{i=0}^j \binom{j}{i} t^i (-1)^{j-i} \sum_{k=0}^d \binom{d}{k} (-1)^{d-k} (d - k)^{j-i}, \text{ redefinindo } k = d - k \\ &= \sum_{i=0}^j \binom{j}{i} t^i (-1)^{j-i} \sum_{k=0}^d \binom{d}{k} (-1)^{d+k} (d - k)^{j-i} \\ &= \sum_{i=0}^j \binom{j}{i} t^i (-1)^{j-i} (-1)^d \sum_{k=0}^d \binom{d}{k} (-1)^k (d - k)^{j-i} \\ &= \sum_{i=0}^j \binom{j}{i} t^i (-1)^{j-i} d! (-1)^d \left\{ \begin{matrix} j-i \\ d \end{matrix} \right\}, \text{ onde o último é o número de Stirling de 2º tipo} \end{aligned}$$

Sabemos que se $d > j - i \implies i > j - d$, o número de Stirling é 0, isto é, $\Delta^d t^j$ é

um polinômio de ordem $(j-d)^+$. Em particular, se $d > j$, teremos um polinômio de ordem 0.

$$\Delta^d Z_t = \sum_{j=0}^m \beta_j \Delta^d t^j + \frac{\theta(B)}{\phi(B)} a_t$$

Defina $m-d = h > 0$. Quando $j = m$, teremos que $\Delta^d t^m$ será um polinômio de ordem h , pelo que vimos acima, dado que o número de Stirling é diferente de 0.

- b. Tomando-se m diferenças obteremos um processo estacionário não invertível.

Tomando m diferenças, teremos um polinômio de ordem 0. Seja, então, se olharmos a forma acima, o único valor diferente de 0 será quando $i = 0, j = d = m$.

$$\Delta^m Z_t = \beta_m m! + \frac{\theta(B)}{\phi(B)} a_t$$

Esse processo não é invertível porque não podemos escrever $a_t = \pi(B)Z_t$, dado à presença do nível.

2. (Questão 31 - 5) Prove que se $W_t = (1-B)Z_t$, então $Z_t = W_t + W_{t-1} + \dots$

Podemos representar $\frac{1}{1-B}$ como:

$$\frac{1}{1-B} = \sum_{j=0}^{\infty} B^j,$$

portanto $Z_t = \sum_{j=0}^{\infty} B^j W_t = W_t + W_{t-1} + W_{t-2} + \dots$

3. (Questão 32 - 5) Prove que, na forma invertida do modelo, $\sum_{j=1}^{\infty} \pi_j = 1$.

Na forma invertida do modelo, ele é escrito da seguinte forma:

$$\pi(B)Z_t = a_t$$

Vamos expandir o polinômio e tomar o valor esperado:

$$\begin{aligned}
a_t &= \left[1 - \sum_{j=1}^{\infty} \pi_j B^j \right] Z_t \\
a_t &= Z_t - \pi_1 Z_{t-1} - \pi_2 Z_{t-2} - \cdots \\
\mathbb{E}\{a_t\} &= \mathbb{E}\{Z_t - \pi_1 Z_{t-1} - \pi_2 Z_{t-2} - \cdots\} \\
0 &= \left(1 - \sum_{j=1}^{\infty} \pi_j \right) \mu \\
0 &= 1 - \sum_{j=1}^{\infty} \pi_j \\
\sum_{j=1}^{\infty} \pi_j &= 1
\end{aligned}$$

Observe que assumimos que $\mu \neq 0$. Isso na verdade é sem perda de generalidade, afinal:

$$\begin{aligned}
\pi(B)Z_t &= a_t \\
\theta(B)\pi(B)Z_t &= \theta(B)a_t \\
\varphi(B)Z_t &= \theta(B)a_t \\
\phi(B)\Delta^d Z_t &= \theta(B)a_t \\
\phi(B)\Delta^d(Z_t + \alpha) &= \theta(B)a_t \\
\phi(B)\Delta^d Y_t &= \theta(B)a_t \\
&\vdots \\
\pi(B)Y_t &= a_t \\
\pi(B)(Z_t + \alpha) &= a_t
\end{aligned}$$

5. (Questão 1 - 6) Prove que se $\rho_j = \phi^{|j|}$, $|\phi| < 1$, então

$$Var(r_j) = \frac{1}{N} \left[\frac{(1 + \phi^2)(1 - \phi^{2j})}{1 - \phi^2} - 2j\phi^{2j} \right],$$

em particular $Var(r_1) = \frac{1}{N}(1 - \phi^2)$.

Observe que, se vale que $\rho_j = \phi^{|j|}$, então essas correlações são do modelo AR(1), como visto em aula:

$$Z_t = \phi Z_{t-1} + a_t$$

Ora, Fuller (2009) mostrou que, nesse caso,

$$\text{Var}(r_j) = \frac{N-j}{N^2} \left[\frac{(1+\phi^2)(1-\phi^{2j})}{1-\phi^2} - 2j\phi^{2j} \right]$$

Acreditamos que a demonstração está fora do escopo deste exercício, pois envolve vários teoremas e bastante manipulações algébricas. Em particular:

$$\begin{aligned} \text{Var}(r_1) &= \frac{N-1}{N^2} \left[\frac{(1+\phi^2)(1-\phi^2)}{1-\phi^2} - 2\phi^2 \right] \\ &= \frac{N-1}{N^2} \left[\frac{1-\phi^4}{1-\phi^2} - 2\phi^2 \right] \\ &= \frac{N-1}{N^2} \left[\frac{1-\phi^4-2\phi^2+2\phi^4}{1-\phi^2} \right] \\ &= \frac{N-1}{N^2} \left[\frac{(1-\phi^2)^2}{1-\phi^2} \right] \\ &= \frac{N-1}{N^2} (1-\phi^2) \end{aligned}$$

-
2. Simulação da distribuição da estatística de teste de Dickey-Fuller Acesse o livro ‘Econometria de Séries Temporais’ 2a. Edição do Rodrigo de Losso Bueno na “Minha Biblioteca” Leia Cap 4.5.1, 4.5.2 e 4.5.3, Pag 116 (ou 134 online)

```
df.simulation <- function(n, Tr, S, e.sd, phi, intercept = 0){
  t.stat <- c(1:S)
  for(i in 1:S){
    # Passo 1
    e <- rnorm(n + Tr, mean = 0, sd = e.sd)
    # Passo 2
    y <- e + intercept
    for(j in (length(phi)+1):(n+Tr)){
      for(k in 1:length(phi)){
        y[j] <- phi[k]*y[(j-k)] + y[j]
      }
    }
    # Passo 3 e 4
    x <- y[(n+1):(n+Tr)]
    mom2 <- sum(x[1:(Tr-1)]*x[1:(Tr-1)])
    # Us
    model <- ar.ols(x, aic = F, order.max = length(phi),
                    intercept = !(intercept==0), demean = F)
    rho.hat <- sum(model$ar)
```

```

    error <- x[(length(phi)+1):Tr] - intercept
    for(k in length(phi)){
      error <- error - model$ar[[k]]*x[(length(phi) - k + 1):(Tr - k)]
    }
    Sn <- sum(error^2)/(Tr-(length(phi)+1))

    t.stat[i] = (rho.hat - 1)*sqrt(mom2)/Sn
  }
  return(t.stat)
}

```

Primeiro, para fins de comparação, vejamos a distribuição quando $\phi = 1$.

```


set.seed(10000)

n <- 50
Tr <- 100
S <- 20000
e.sd <- 1
phi <- c(1)

t.stat <- df.simulation(n,Tr,S,e.sd,phi)
hist(t.stat, breaks = 50 , freq = F, col = 'grey',
     main = 'Densidade da t-estatística')

```

Densidade da t-estatística



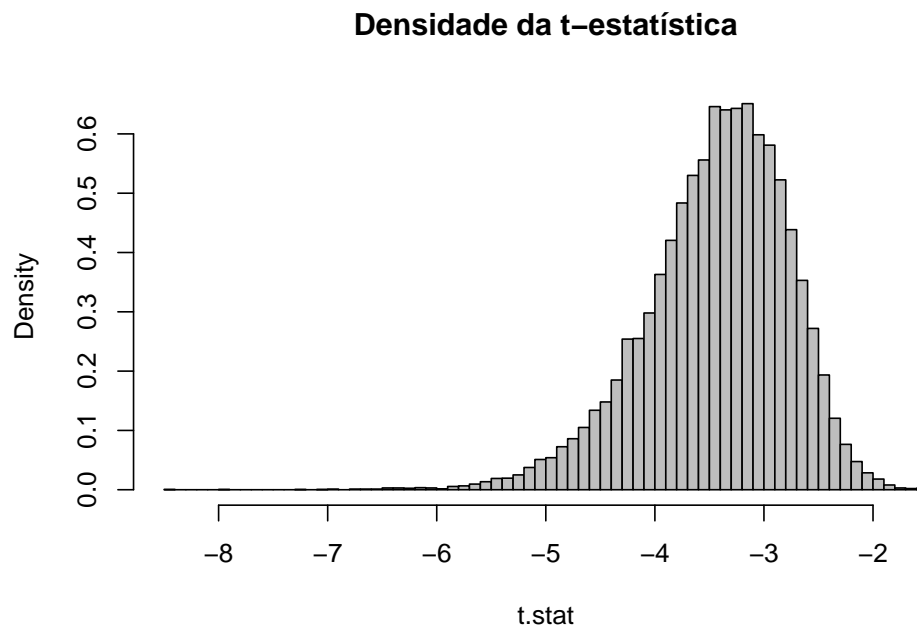
Vemos que o gráfico é similar com o exemplo do livro, o que é um *sanity check*

interessante.

2.1 Simule os valores críticos da estatística de teste DF, como proposto no Cap 4.5.1, após eq (2) com $\phi_1 = 0.8$.

```
phi <- c(0.8)

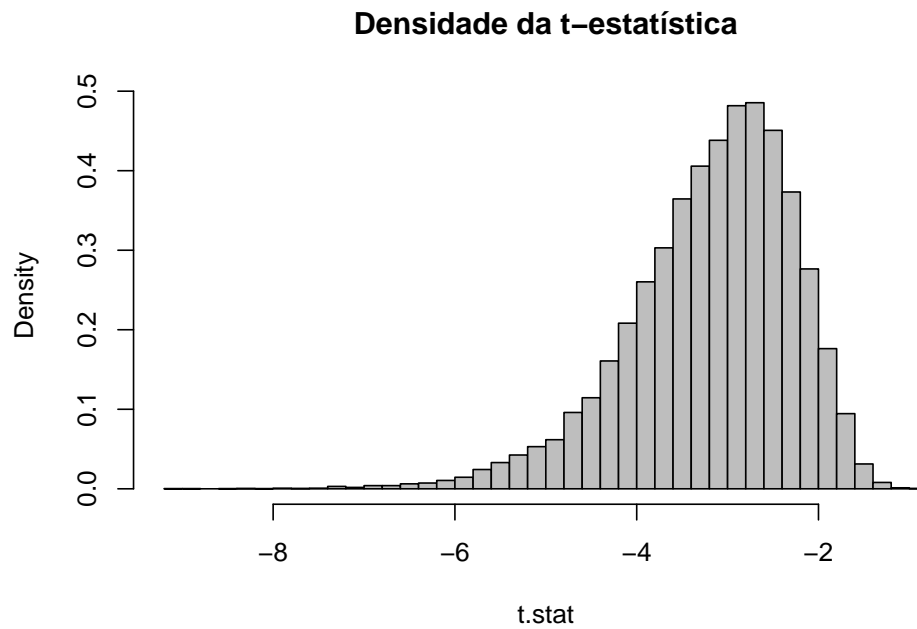
t.stat <- df.simulation(n,Tr,S,e.sd,phi)
hist(t.stat, breaks = 50 , freq = F, col = 'grey',
     main = 'Densidade da t-estatística')
```



2.2 Repita a simulação, mas agora adicione termos autoregressivos no modelo, verifique que a distribuição da estatística de teste permanece inalterada.

```
phi <- c(0.8,-0.4, 0.2)

t.stat <- df.simulation(n,Tr,S,e.sd,phi)
hist(t.stat, breaks = 50 , freq = F, col = 'grey',
     main = 'Densidade da t-estatística', )
```

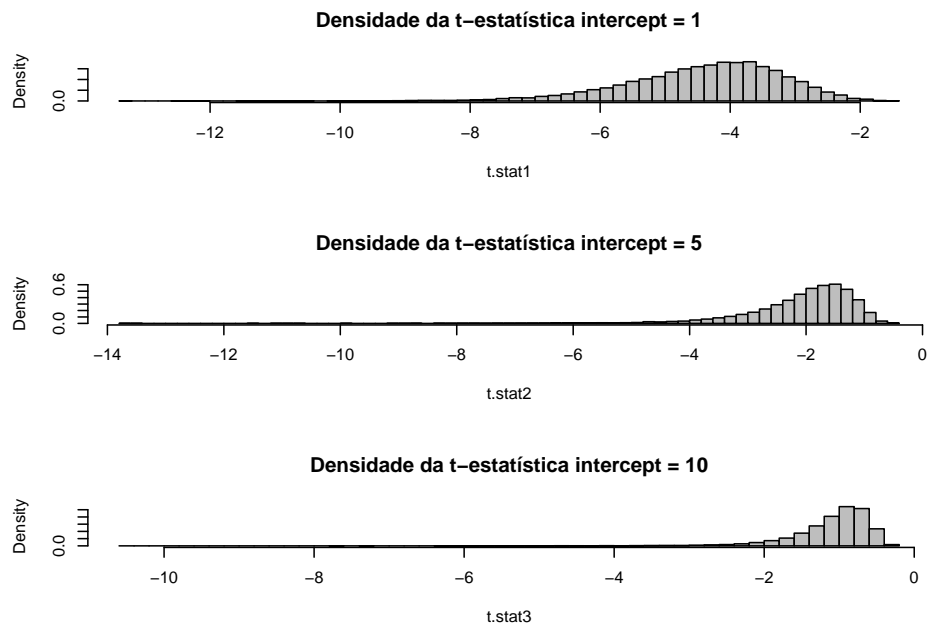


De fato as distribuições são bem similares, como podemos observar pelos gráficos. Isso é provado no Apêndice B do livro de referência.

2.3 Adicione intercepto e verifique se a nova distribuição da estatística de teste muda.

```
phi <- c(0.8, -0.4, 0.2)


t.stat1 <- df.simulation(n,Tr,S,e.sd,phi, intercept = 1)
t.stat2 <- df.simulation(n,Tr,S,e.sd,phi, intercept = 5)
t.stat3 <- df.simulation(n,Tr,S,e.sd,phi, intercept = 10)
```



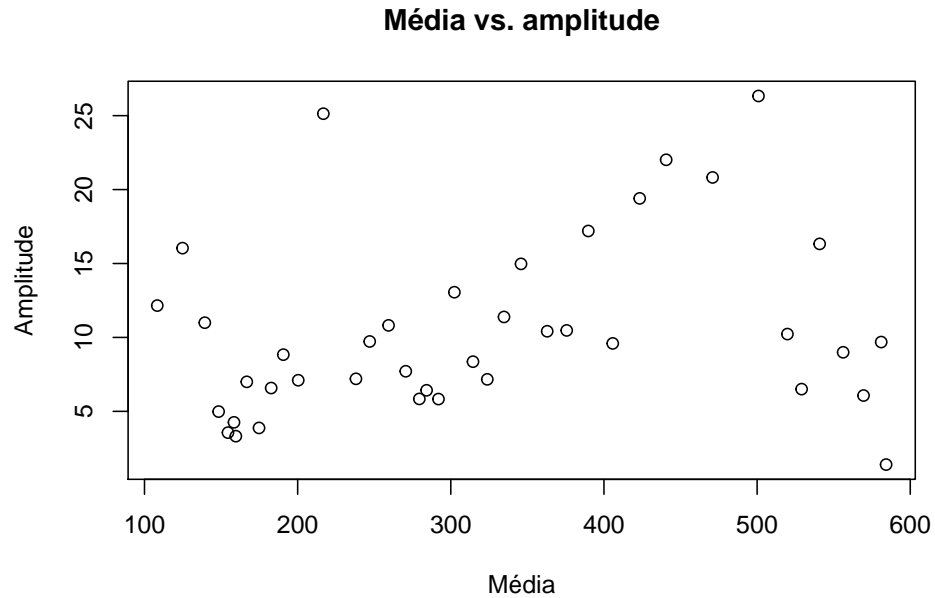
Vemos que a distribuição varia conforme o intercepto. Quando o intercepto é pequeno, a distribuição parece não mudar muito, porém quando ele aumenta, o histograma vai mudando um pouco de formato, concentrando-se mais e mais próximo de 0.

3. Identificação do modelo: Identifique o modelo ARIMA para a série de dados de inflação

Primeiro podemos verificar com que tipo de série estamos lidando através de um plot do gráfico. Os dados são de caráter mensal e se inicia em agosto de 1994 até agosto de 2020. Não há dados faltantes nem duplicados.




Vejamos se é necessário uma transformação para estabilizar a variância. O que faremos é dividir a nossa série temporal em um conjunto de 8 observações consecutivas, e estimar a média e a amplitude de cada um.




É difícil de tirar grandes conclusões a partir desse gráfico, mas podemos supor que a média cresce linearmente com a amplitude. Sendo assim, sabemos que a transformação indicada é a logarítmica.

Transformação do Ipca pelo log



Está claro que essa série tem uma tendência, pelo fato de estarmos tomando ipca acumulado. Vamos capturar o valor mensal, portanto:

Ipca mensal

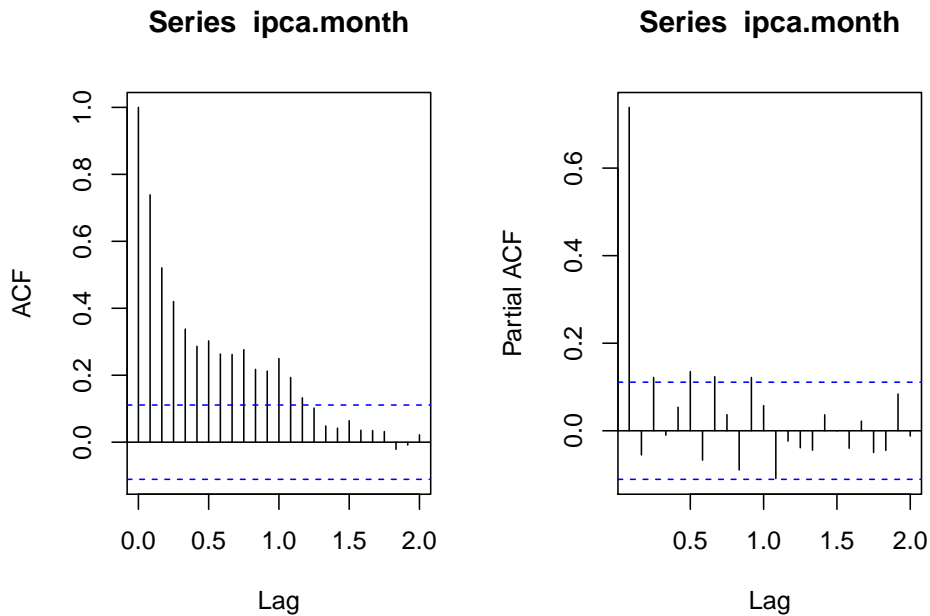


Checando o Teste Dickey-Fuller aumentado, temos que o p-valor é menor do que 0.01, o que faz com que rejeitemos a hipótese de que a série é não estacionária. Concluímos que esse modelo já pode ser utilizado para identificar os parâmetros p e q .

```
tseries::adf.test(ipca.month, alternative = "stationary")
```

```
##
## Augmented Dickey-Fuller Test
##
## data: ipca.month
## Dickey-Fuller = -4.8786, Lag order = 6, p-value = 0.01
## alternative hypothesis: stationary
```

Antes disso, vejamos a ACF e a PACF




Olhando o gráfico fica difícil discernir. Mas é aparente que a PACF morre logo nos primeiros valores. Portanto, apenas olhando os gráficos, chegaríamos em um modelo $AR(p)$. Em contrapartida, vamos ver como se comportam os critérios de informação. Vamos obter em um dataframe o AIC, BIC e AICC. Estamos tomando $K = L = \log(N)$ como valor máximo.

p	q	AIC	BIC	AICC
0	0	-2419.676	-2412.190	-2419.638
0	1	-2591.263	-2580.034	-2591.185
0	2	-2632.593	-2617.620	-2632.462
0	3	-2645.967	-2627.252	-2645.771
0	4	-2663.121	-2640.663	-2662.845
0	5	-2661.393	-2635.192	-2661.025
1	0	-2668.081	-2656.852	-2668.003
1	1	-2666.535	-2651.563	-2666.404

p	q	AIC	BIC	AICC
1	2	-2672.661	-2653.946	-2672.465
1	3	-2673.231	-2650.773	-2672.955
1	4	-2671.893	-2645.692	-2671.524
1	5	-2673.986	-2644.042	-2673.511
2	0	-2666.359	-2651.387	-2666.229
2	1	-2669.995	-2651.280	-2669.799
2	2	-2674.126	-2651.668	-2673.850
2	3	-2672.288	-2646.087	-2671.919
2	4	-2670.485	-2640.541	-2670.009
2	5	-2673.840	-2640.153	-2673.244
3	0	-2670.728	-2652.013	-2670.532
3	1	-2668.763	-2646.305	-2668.488
3	2	-2683.002	-2656.801	-2682.633
3	3	-2681.298	-2651.354	-2680.823
3	4	-2679.882	-2646.195	-2679.286
3	5	-2691.250	-2653.820	-2690.519
4	0	-2668.739	-2646.281	-2668.464
4	1	-2667.310	-2641.109	-2666.942
4	2	-2670.393	-2640.449	-2669.918
4	3	-2685.374	-2651.687	-2684.778
4	4	-2684.140	-2646.710	-2683.409
4	5	-2689.527	-2648.354	-2688.647
5	0	-2668.143	-2641.942	-2667.775
5	1	-2665.715	-2635.771	-2665.240
5	2	-2667.857	-2634.170	-2667.261
5	3	-2684.414	-2646.984	-2683.683
5	4	-2679.120	-2637.947	-2678.240
5	5	-2683.735	-2638.819	-2682.692


Os critérios AIC e AICC tem informação mínima quando $p = 3, q = 5$, o modelo com ordem alta (como já era esperado). Enquanto isso, o BIC subestima a ordem do modelo com $p = 1, q = 0$, o que corrobora os gráficos ACF e PACF.

O seguinte gráfico apenas ajuda a identificar quais os índices do dataframe que contêm os parâmetros que minimizam as informações.



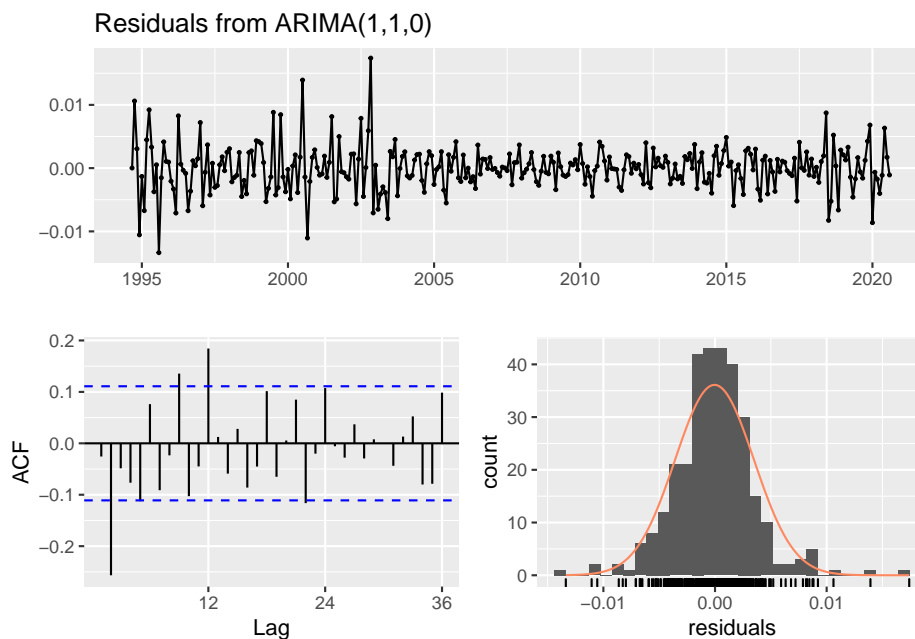
Agora nós vamos ajustar os dois modelos encontrados aos dados e analisar os resíduos.

```
model1 = arima(ipca.month, order = c(3, 1, 5))
checkresiduals(model1)
```



```
##
## Ljung-Box test
##
```

```
## data: Residuals from ARIMA(3,1,5)
## Q* = 36.547, df = 16, p-value = 0.002428
##
## Model df: 8. Total lags used: 24
model2 = arima(ipca.month, order = c(1, 1, 0))
checkresiduals(model2)
```



```
##
## Ljung-Box test
##
## data: Residuals from ARIMA(1,1,0)
## Q* = 73.982, df = 23, p-value = 2.908e-07
##
## Model df: 1. Total lags used: 24
```

A partir dos gráficos, podemos concluir que os resíduos não são normais. Os resultados do teste de Ljung-Box indicam que ambos os modelos não possuem resíduos não correlacionados. Porém, o p-valor do modelo ARIMA(1, 1, 0) é menor, o que indica um melhor ajuste do modelo ARIMA(3, 1, 5). Vamos calcular o MAPE de cada um dos modelos ajustados:

```
## [1] "MSE do ARIMA(3, 1, 5): " "1.03957837630611e-05"
## [1] "MSE do ARIMA(1, 1, 0): " "1.24579053791551e-05"
```

Observamos que o MSE do ARIMA(3, 1, 5) é melhor. Portanto, escolhemos este modelo para nossos dados.

Referências

Fuller, Wayne A. 2009. *Introduction to Statistical Time Series*. Vol. 428. John Wiley & Sons.